

Visión computacional para imágenes y video (TC4033.10)**4.2 Google Colab - Algoritmos de
mejoramiento de imágenes usando
operaciones morfológicas**

Leonardo Javier Nava Castellanos A01750595

Eva Denisse Vargas Sosa A01377098

Juan Pablo Salazar Pérez A01796000

Victor Daniel Bohorquez Toribio A01794554

Oscar Becerra Alegría A01795611

Profesores:**Dr. Gilberto Ochoa Ruiz****Profesora María Guadalupe Marcos Abularach**

Domingo 2 de febrero de 2025

“Apegándome a la Integridad Académica de los Estudiantes del Tecnológico de Monterrey, me comprometo a que mi actuación en esta actividad esté regida por la integridad académica. En congruencia con el compromiso adquirido, realizaré este trabajo de forma honesta y personal, para reflejar, a través de él, mi conocimiento y aceptar, posteriormente, la evaluación obtenida”.

Discusión de resultados:

Erosión:




Figura 1. Método de erosión

La Figura 1 muestra el resultado de una operación morfológica de erosión aplicada a una imagen binaria que contiene múltiples objetos circulares. La erosión es una técnica fundamental en el procesamiento de imágenes, utilizada para eliminar pequeños detalles y reducir el tamaño de los objetos. En la imagen, se observa cómo la erosión afecta progresivamente los objetos a medida que se aumentan el tamaño del kernel y el número de iteraciones. Según Gonzalez y Woods (2018), la erosión se define como la reducción de regiones blancas en una imagen binaria utilizando un elemento estructurante, lo que puede ser útil para eliminar ruido o separar objetos conectados.

En la primera fila de la imagen, se utiliza un kernel de (3,3), lo que produce una disminución moderada en el tamaño de los objetos conforme se incrementan las iteraciones. En la segunda fila, con un kernel de (5,5), la erosión es más agresiva, lo que resulta en la desaparición de algunos objetos más pequeños después de pocas iteraciones. Finalmente, en la tercera fila, con un kernel de (7,7), los objetos se reducen drásticamente en tamaño, y tras solo tres iteraciones, la mayoría desaparece. Esto es consistente con la teoría presentada por Gonzalez y Woods (2018), quienes explican que el tamaño del elemento estructurante determina la magnitud del efecto de la erosión en la imagen.

El análisis de estos resultados sugiere que la elección del kernel y el número de iteraciones deben seleccionarse cuidadosamente dependiendo del objetivo del procesamiento de imágenes. Si el propósito es eliminar ruido sin afectar demasiado los objetos principales, un kernel pequeño con pocas iteraciones es más adecuado. En cambio, si se busca segmentar estructuras o eliminar pequeños objetos no deseados, un kernel más grande y múltiples iteraciones pueden ser más efectivos. Gonzalez y Woods (2018) enfatizan la importancia de comprender la estructura de la imagen y el impacto de las transformaciones morfológicas para optimizar los resultados en aplicaciones prácticas, como la detección de bordes y la mejora del contraste en imágenes médicas.

Dilatación

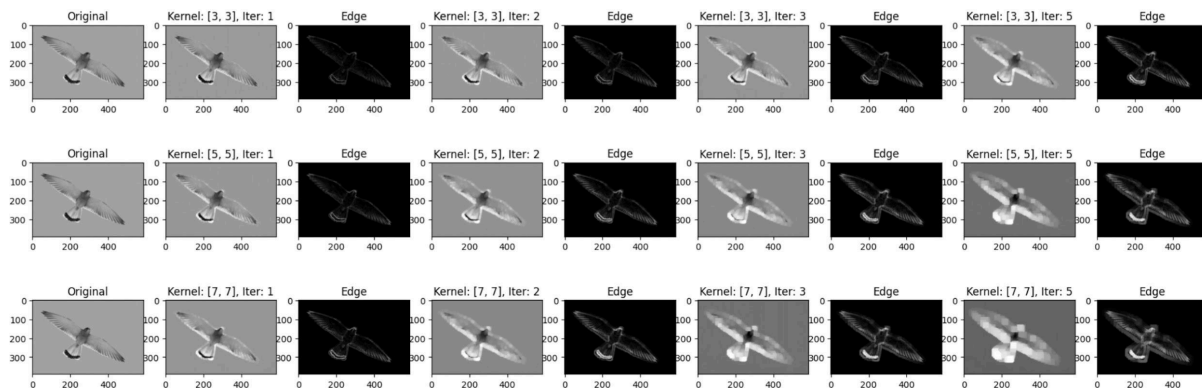


Figura 2. Método de dilatación

En la Figura 2, se muestra el resultado de aplicar el método morfológico de dilatación. Según Gonzalez & Wood (2018), la dilatación hace que los objetos brillantes en una imagen binaria o en escala de grises aumenten y elimina los pequeños detalles que puedan generar ruido a la imagen. En cada iteración, la dilatación hace que los objetos dentro de la imagen se expandan. La dilatación también mejora la conectividad entre regiones, cerrando pequeños huecos en los bordes, ayudando a la segmentación y la detección de objetos.

En la imagen utilizada y con un kernel de $([3,3])$ la expansión es controlada y los detalles del pájaro se mantienen, mientras que un kernel de $([5,5])$ o $([7,7])$ tiene como resultado un crecimiento más agresivo, lo que genera una integración progresiva de los bordes. Dicho comportamiento se puede observar en la segunda y tercera fila de la imagen, donde los contornos del pájaro se hacen cada vez más gruesos y las estructuras finas desaparecen conforme a las iteraciones.

Comparando la imagen original con las imágenes dilatadas, se observa que la dilatación resalta los bordes del pájaro en las primeras iteraciones. Sin embargo, en iteraciones avanzadas con kernels un poco más grandes, el pájaro pierde ciertos detalles y los bordes se engrosan.

En conclusión, esta figura ilustra como la dilatación afecta la estructura de los objetos dependiendo del tamaño del kernel y el número de iteraciones. Un kernel pequeño $([3,3])$ con pocas iteraciones preserva mejor los detalles, mientras que un kernel grande $([7,7])$ con varias iteraciones tiende a suavizar y fusionar ciertas estructuras.

Opening & Closing




Figura 3. Método de apertura y cierre

El "opening" puede ayudar a separar los huesos y resaltar las fracturas o líneas de fractura. Al usar un kernel pequeño como el de (3,3) podemos eliminar detalles muy pequeños y ruido fino, los objetos más grandes y las estructuras principales se conservan en gran medida. Al incrementar el kernel a (7,7) se pueden eliminar los objetos más grandes y detalles más prominentes. Solo objetos muy grandes y las estructuras más robustas permanecen.

El "closing" puede ayudar a mejorar la visualización de la estructura ósea y facilitar la detección de lesiones. Al usar un kernel pequeño como (3,3) rellenar huecos pequeños y suavizar contornos sutilmente, no afecta significativamente objetos grandes ni a la estructura general. Al incrementar el kernel a (7,7) podemos rellenar huecos más grandes poder incluso conectar objetos que estaban separados por pequeñas distancias, suaviza contornos de manera más notable.

En conclusión el tamaño del kernel determina la escala de los detalles que se ven afectados por las operaciones de "opening" y "closing". Un kernel pequeño afecta principalmente a detalles finos y ruido, mientras que un kernel grande tiene un impacto mayor en objetos y estructuras de mayor tamaño.

Consideraciones adicionales:

La forma del kernel también influye en el resultado. Los kernels circulares, por ejemplo, tienden a afectar a los objetos de manera más uniforme, mientras que los kernels rectangulares pueden tener un efecto direccional.

La elección del tamaño del kernel dependerá del objetivo específico del procesamiento de imágenes. Si se busca eliminar el ruido fino, un kernel pequeño será suficiente. Si se necesita eliminar objetos más grandes o conectar estructuras, se requerirá un kernel más grande.

En el contexto de imágenes radiográficas:

En radiografías, el tamaño del kernel debe ser cuidadosamente considerado para no eliminar información diagnóstica importante. Un kernel demasiado grande podría eliminar estructuras pequeñas pero relevantes, mientras que un kernel demasiado pequeño podría no ser efectivo para reducir el ruido o mejorar la segmentación.

Referencias:

Gonzalez, R. C., & Woods, R. E. (2018). *Digital Image Processing* (4th ed.). Pearson.

Image Enhancement Techniques for Digital Radiography (2017), IEEE
<https://ieeexplore.ieee.org/document/8229130>